PROPOSAL TUGAS BESAR ANALISIS BIG DATA
Sains Data Institut Teknologi Sumatera 2026

Judul Tugas Besar

Prediksi Kualitas Air di England berbasis Parameter Fisikokimia dan Tekanan Urbanisasi menggunakan Medallion Architecture

Identitas Mahasiswa

No	Nama Peran	NIM	Username Github
1	Nobel Nizam Fathirizki	123450117	NobelNizam
2	Daffa Hadyan Navista	123450025	DaffaHadyanN
3	Enggli Rahmadhani	123450043	engliramdhnii
4	Khoirul Anam	122450039	khoirulanama
5	Gracia Yoan Nababan	123450120	graciayoan

Tema Tugas Besar

SDG 6 – Air Bersih dan Sanitasi

Ringkasan Proposal

Ringkasan proposal (maksimum 300 kata) berisi **Urgensi, tujuan, metode, dan luaran yang dihasilkan/targetkan**

Urgensi: Kualitas air sungai merupakan isu kritis dalam pencapaian SDG 6 (Air Bersih dan Sanitasi). Tekanan urbanisasi yang masif di England menyebabkan degradasi kualitas air secara signifikan. Dataset komprehensif mencakup 2,82 juta rekaman kualitas air (1940–2023) membuka peluang analisis berbasis machine learning berskala besar yang belum banyak dimanfaatkan secara sistematis.

Tujuan: Membangun sistem prediksi kualitas air sungai berbasis parameter fisikokimia dan tekanan urbanisasi (kepadatan populasi) menggunakan Medallion Architecture untuk menghasilkan model ML yang akurat dan terukur. Jangka panjang, arsitektur yang dibangun diharapkan dapat diadaptasi untuk mendukung pemantauan kualitas air di Indonesia sebagai kontribusi terhadap SDG 6 nasional.

Metode: ***Medallion Architecture*** dengan alur sebagai berikut:

Bronze Layer: Ingesti data mentah. CSV kualitas air disimpan di MinIO/HDFS, serta data populasi GeoTIFF (WorldPop) dimuat ke object storage.

Silver Layer: Pembersihan dan transformasi data menggunakan Spark SQL & PySpark; konversi GeoTIFF → CSV via rasterio/GDAL; serta *spatial join* antara data kualitas air dan kepadatan populasi menggunakan GeoPandas + Spark.

Gold Layer: Pembentukan *feature table* (8 parameter fisikokimia + kepadatan populasi), pelabelan Water Quality Index (WQI) berbasis kelas CCME, dan penyimpanan data siap ML dalam format Parquet/Delta Lake.

Pemodelan ML: Pelatihan model Random Forest dan XGBoost, dilacak menggunakan MLflow, dievaluasi dengan metrik RMSE dan Accuracy.

Infrastruktur: Apache Spark, MinIO/HDFS, Apache Airflow, dan Docker Compose sebagai *container stack*.

Target:

Pipeline data end-to-end berbasis Medallion Architecture yang dapat direproduksi

Model prediksi WQI dengan performa terukur (RMSE ≤ 0,35; Accuracy ≥ 85%)

Dashboard visualisasi interaktif via Apache Superset

Eksperimen ML terdokumentasi melalui MLflow

Kata kunci

Isian 5 kata kunci yang dipisahkan dengan tanda titik koma (;)

Kata Kunci :*Water Quality Prediction; Medallion Architecture; Apache Spark; Machine Learning; SDG 6*

Substansi Usulan

Petunjuk: Pengusul hanya diperkenankan mengisi di tempat yang telah disediakan (diberi warna ....) sesuai dengan petunjuk pengisian dan tidak diperkenankan untuk memodifikasi template menghapus setiap bagian.

A. RINGKASAN PAPER

Pilih satu paper yang paling relevan dengan proyek Anda dan tuliskan ringkasannya disini. Jangan melebihi 2 halaman untuk bagian ini.

Tabel 1. Rincian Paper yang diulas

Judul	*A Comprehensive Dataset of Surface Water Quality Spanning 1940-2023 for Empirical and ML Adopted Research*
Penulis	Md. Rajaul Karim, M. M. Mahbubul Syeed, Ashifur Rahman, Khondkar Ayaz Rabbani, Kaniz Fatema, Razib Hayat Khan, Md Shakhawat Hossain, Mohammad Faisal Uddin
Jurnal	*Scientific Data*
Tahun	2025
URL	https://doi.org/10.1038/s41597-025-04715-4

1. LATAR BELAKANG

Gambarkan konteks paper: apa motivasi dan masalah yang dikemukakan para penulis? Masalah apa yang ingin mereka selesaikan atau pengetahuan apa yang ingin mereka temukan?

Pemantauan kualitas air permukaan sangat krusial untuk perlindungan ekosistem dan kesehatan masyarakat. Namun, paparan tekanan lingkungan, termasuk urbanisasi yang masif, terus menyebabkan degradasi kualitas air secara signifikan. Para penulis termotivasi oleh kenyataan bahwa meskipun data pemantauan banyak tersedia, belum ada upaya komprehensif untuk menyediakan dataset kualitas air permukaan yang terharmonisasi dalam skala global. Masalah utama yang ingin diselesaikan oleh riset ini adalah mengatasi kelangkaan dataset berskala besar yang bersih, konsisten, dan siap pakai untuk mendukung evaluasi empiris serta analitik prediksi berbasis *Machine Learning* (ML) lintas wilayah.

2. RINGKASAN KONTRIBUSI

Setiap paper memberikan sesuatu yang baru. Uraikan kontribusi utamanya - algoritma baru, hasil eksperimen, dataset baru, atau analisis baru

Kontribusi utama penelitian ini adalah perakitan dan publikasi dataset kualitas air berskala masif, terdiri dari 2,82 juta rekaman yang mencakup 8 parameter fisikokimia (termasuk pH, *Dissolved Oxygen*, dan Amonia) dengan rentang waktu 1940 hingga 2023. Para peneliti mengekstraksi dan mengharmonisasi data mentah dari 5 negara, salah satunya England. Selain itu, penelitian ini berkontribusi dalam membangun pipeline rekayasa data yang mentransformasi data mentah menjadi status ML-Ready melalui tahap harmonisasi komprehensif yaitu, konversi bahasa, standardisasi unit metrik, penyeragaman format waktu, penanganan missing values, hingga perhitungan agregat Water Quality Index (WQI).

3. KETERBATASAN DAN DISKUSI

Identifikasi keterbatasan metodologi atau klaim generalisasi paper ini secara kritis. Apakah keterbatasan tersebut mengubah cara Anda menilai temuan paper ini?

Keterbatasan utama metodologi penelitian ini terletak pada proses reduksi datanya untuk mencapai keseragaman. Dengan membatasi spesifikasi hanya pada 8 parameter umum di 5 negara, penulis harus membuang baris data yang memiliki parameter lebih atau kurang dari itu. Hal ini berakibat pada penyusutan drastis dari 450 juta data awal menjadi hanya 2,82 juta rekaman akhir. Selain itu, penggunaan teknik imputasi median untuk menangani nilai kosong (*Missing Value Handling*) berisiko menyamarkan anomali atau lonjakan insiden polusi ekstrem yang sebenarnya vital. Keterbatasan ini menyadarkan kami bahwa dalam merancang transformasi di arsitektur *pipeline*, penanganan agregasi harus dilakukan dengan hati-hati agar tidak menghilangkan pola kritis akibat tekanan urbanisasi.

4. MENGAPA PAPER INI?

Dari sekian banyak paper, mengapa Anda memilih ini? Apa yang menarik dari topiknya? Setelah membacanya, apakah Anda mendapat apa yang diharapkan?

Paper ini cocok untuk proposal kami karena memiliki korelasi langsung secara geografis dan metodologis. Pertama, dataset ini menyoroti *England* sebagai salah satu sumber data kualitas air terbesar yang mereka proses, yang sejalan dengan fokus spasial Tugas Besar kami. Kedua, alur kerja *Data Acquisition, Harmonization, and Validation* yang mereka paparkan pada dasarnya adalah bentuk implementasi praktis dari *Medallion Architecture* (ingesti, pembersihan, penyiapan fitur) sebelum diumpankan pada algoritma klasifikasi. Paper ini memberikan *benchmark* yang realistis tentang tantangan yang akan kami hadapi dalam mengolah jutaan data historis.

5. KONTEKS RISET YANG LEBIH LUAS

Hubungkan paper ini dengan tema-tema besar dalam Big Data: pemrosesan terdistribusi, manajemen kualitas data, skalabilitas, analitik real-time vs. batch, atau kesiapan data untuk machine learning. Apakah metode ini berpotensi diterapkan ke domain lain?

Dalam konteks besar Analisis *Big Data*, riset ini adalah representasi ideal dari topik Manajemen Kualitas Data dan Kesiapan Data untuk *Machine Learning*. Tahap konversi unit, penyeragaman format waktu, dan pembersihan nilai kosong secara terdistribusi yang dilakukan penulis merepresentasikan fungsi inti dari *Silver Layer* dalam lingkungan *Big Data*. Sementara itu, langkah kalkulasi WQI sebelum data dimasukkan ke repositori siap pakai merupakan karakteristik dari kurasi data di *Gold Layer*. Metodologi *pipeline* terstruktur ini tidak hanya berlaku untuk kualitas air, tetapi berpotensi diadopsi di domain lain yang mengandalkan integrasi dataset yang besar, heterogen, dan rentan terhadap anomali.

B. DESKRIPSI PROYEK

1. TUJUAN UTAMA

Rumuskan tujuan proyek Anda, idealnya sebagai pertanyaan ilmiah. Contoh: “Apakah arsitektur Medallion berbasis Spark dapat meningkatkan throughput pemrosesan data ekspor dibandingkan pipeline tradisional?” Jelaskan mengapa tujuan ini penting dan memungkinkan dicapai. Sebutkan tujuan sekunder (stretch goal) jika ada, dihubungkan dengan paper yang Anda pilih.

"Apakah Medallion Architecture berbasis Apache Spark mampu memproses dataset kualitas air permukaan berskala jutaan rekaman secara efisien, dan sejauh mana integrasi parameter

tekanan urbanisasi (kepadatan populasi) dapat meningkatkan akurasi prediksi Water Quality Index (WQI) dibandingkan model yang hanya menggunakan parameter fisikokimia?"

Mengapa penting?

1. Relevansi data & skala Dataset yang digunakan mencakup 2,82 juta rekaman kualitas air permukaan England (1940–2023), skala ini tidak dapat diproses secara efisien tanpa pendekatan big data menjadikan Medallion Architecture pilihan yang tepat dan relevan secara teknis.

2. Gap penelitian yang nyata Studi sebelumnya seperti penelitian kualitas air di platform Spark *(ResearchGate, 2022)* menunjukkan bahwa integrasi faktor spasial urbanisasi ke dalam model prediksi masih jarang dilakukan secara *end-to-end* dalam satu pipeline terstruktur.

3. Dukungan bukti empiris urbanisasi Paper tentang hubungan pola spasial kualitas air dan perkembangan urban di Shanghai *(ResearchGate)* serta studi berbasis remote sensing *(MDPI Remote Sensing, 2026)* mengkonfirmasi bahwa kepadatan populasi adalah variabel penjelas yang signifikan terhadap degradasi kualitas air memperkuat relevansi penambahan fitur pop_density.

4. Feasibility teknis seluruh infrastruktur yang digunakan (Apache Spark, MinIO, Airflow, Docker) bersifat *open-source* dan dapat dijalankan secara lokal maupun cloud, sehingga proyek ini realistis dikerjakan dalam konteks tugas besar akademik.

Tujuan sekunder: Apakah pipeline Medallion Architecture yang dibangun untuk data England dapat diadaptasi dengan perubahan minimal untuk dataset kualitas air Indonesia?

2. STUDI KASUS / DOMAIN APLIKASI

Domain apa yang menjadi fokus proyek Anda? Berikan contoh konkret: apa input datanya dan apa output analitik yang diharapkan? Jika sudah dijelaskan dalam ringkasan paper, maka buat lebih detail disini.

Domain:

Big Data Engineering: Membangun pipeline skala jutaan rekaman dengan Medallion Architecture

Environmental Informatics: Analisis kualitas air berbasis parameter fisikokimia & spasial

Machine Learning: Prediksi & klasifikasi Water Quality Index (WQI)

Domain aplikasinya secara spesifik adalah pemantauan kualitas air permukaan (surface water quality monitoring) dengan pendekatan *data-driven* yang mengintegrasikan data lingkungan dan tekanan sosial-demografis (urbanisasi).

Input: 2,82 juta baris data fisikokimia sungai England (CSV) + peta kepadatan populasi resolusi tinggi (GeoTIFF) → diproses melalui Medallion Architecture berbasis Apache Spark.

Output: Tabel Gold Layer berformat Parket yang dapat dikirim via Spark SQL, model prediksi WQI kelas I–V dengan akurasi ≥85%, serta dashboard interaktif yang memvisualisasikan korelasi urbanisasi terhadap degradasi kualitas air sungai di seluruh England.

3. DATASET

Sebutkan dataset yang akan digunakan (sumber, ukuran, format). Jelaskan pra pemrosesan yang direncanakan. Jika mengumpulkan data sendiri, jelaskan caranya dan estimasi waktu yang diperlukan.

1. Dataset Primer

Sumber : Figshare (Nature Scientific Data, 2025)

Format : CSV

Ukuran : ~2,82 juta baris

2. Dataset Pendukung 1

Sumber : WorldPop Hub (ID: 49412)

Format : GeoTIFF

Ukuran : 2.3MB

3. Dataset Pendukung 2

Sumber : WorldPop Hub (ID: 50089)

Format : GeoTIFF

Ukuran : 26.3MB

Prapemrosesan Dataset Primer dilakukan di Silver Layer menggunakan Spark SQL & PySpark, meliputi:

Filtering geografis: Memfilter hanya rekaman yang berasal dari stasiun pemantauan di wilayah England menggunakan kolom koordinat (latitude, longitude) dengan bounding box (49.8°N – 55.8°N, 6.4°W – 1.8°E).

Handling missing values: Kolom parameter fisikokimia (DO, CODMn, NH3_N, TP, TN, pH, turbidity, conductivity) yang bernilai null/negatif/outlier ekstrem dihapus atau diimputasi menggunakan median per stasiun per tahun via Window function PySpark.

Normalisasi tipe data: Kolom tanggal dikonversi ke format DateType standar; nilai string numerik dikonversi ke FloatType.

Deduplication: Baris duplikat berdasarkan (station_id, date) dihapus menggunakan dropDuplicates().

Pelabelan WQI: Setelah pembersihan, setiap rekaman diberi label kelas WQI (Kelas I–V) berdasarkan standar CCME WQI menggunakan UDF PySpark yang mengkalkulasi skor dari kombinasi parameter fisikokimia.

Pra Pemrosesan Dataset Pendukung 1 dan 2 dilakukan di Silver Layer menggunakan Spark SQL & PySpark, meliputi:

Konversi format: File GeoTIFF dikonversi menjadi CSV tabular menggunakan library rasterio dan GDAL, menghasilkan kolom (lon, lat, pop_density) dan (lon, lat, pop_count) per sel grid.

Reprojeksi CRS: Koordinat distandarisasi ke sistem referensi agar kompatibel dengan koordinat stasiun kualitas air.

Spatial Join: Setiap rekaman kualitas air di-*join* dengan nilai pop_density terdekat dari grid WorldPop menggunakan GeoPandas (join nearest) yang kemudian diparalelkan via PySpark untuk efisiensi pada data besar.

Agregasi spasial: Nilai populasi per sel grid diagregasi ke level stasiun menggunakan buffer radius 5 km, lalu dirata-ratakan sebagai representasi tekanan urbanisasi lokal.

4. ARSITEKTUR DAN TEKNOLOGI

Jelaskan komponen teknis utama yang akan digunakan dan bagaimana mereka berinteraksi. Jika menggunakan Medallion Architecture, jelaskan setiap lapisannya. Tunjukkan mana yang diimplementasikan sendiri dan mana yang menggunakan konfigurasi yang sudah ada.



Bronze Layer: Raw Ingestion

Lapisan ini berfungsi sebagai *landing zone* data mentah tanpa transformasi apapun.

Water Quality CSV dimuat langsung ke MinIO (S3-compatible object storage) sebagai bucket bronze/water-quality/.

GeoTIFF WorldPop (density & counts) disimpan di bucket bronze/worldpop/ pada MinIO yang sama.

Proses ingesti dikelola oleh Apache Airflow DAG (dag_bronze_ingest.py) yang menjadwalkan pengunduhan otomatis dari sumber Figshare dan WorldPop Hub.

Diimplementasikan sendiri: DAG Airflow untuk ingesti, konfigurasi bucket MinIO.

Menggunakan konfigurasi tersedia: Docker image resmi minio/minio dan apache/airflow.

Silver Layer: Cleaning & Integration

Lapisan ini melakukan transformasi, pembersihan, dan integrasi lintas dataset.

Apache Spark (PySpark) membaca data dari Bronze MinIO, menjalankan filter wilayah England, pembersihan nilai anomali, dan normalisasi tipe data.

rasterio + GDAL mengkonversi GeoTIFF WorldPop menjadi tabular CSV yang tersimpan kembali di MinIO bucket silver/worldpop-csv/.

GeoPandas + Spark melakukan *spatial join* antara koordinat stasiun kualitas air dengan nilai populasi terdekat dari grid WorldPop.

Hasil Silver Layer disimpan dalam format Parquet di MinIO bucket silver/wq-integrated/.

Diimplementasikan sendiri: Script PySpark untuk cleaning & spatial join, konversi GeoTIFF.

Menggunakan konfigurasi tersedia: Docker image bitnami/spark, library rasterio, geopandas.

Gold Layer: Feature Engineering & ML-Ready

Lapisan ini menghasilkan data siap pakai untuk *machine learning*.

Feature table dibangun dengan 9 kolom: 8 parameter fisikokimia + pop_density, disimpan dalam format Delta Lake di bucket gold/features/.

WQI labeling menggunakan PySpark UDF berbasis standar CCME menghasilkan kolom wqi_class (Kelas I–V).

Data Gold dapat dikirim langsung via Spark SQL atau dibaca oleh model ML.

Diimplementasikan sendiri: UDF WQI labeling, schema Delta Lake.

Menggunakan konfigurasi tersedia: delta-io/delta library.

ML & Monitoring Layer

Random Forest & XGBoost dilatih menggunakan pyspark.ml dan xgboost4j-spark terhadap Gold Layer.

Setiap eksperimen (hyperparameter, metrik, artefak model) dicatat secara otomatis oleh MLflow Tracking Server.

Evaluasi dilakukan terhadap *held-out test set* (80/20 split) menggunakan RMSE dan Accuracy.

Apache Superset terhubung ke Spark SQL/Delta Lake untuk membuat dashboard visualisasi interaktif.

5. METODE PEMBANDING (BASELINE)

Metode apa yang digunakan sebagai pembanding? Misalnya: pemrosesan sekuensial tanpa distribusi, pipeline sederhana satu lapisan, atau implementasi yang telah dipublikasikan. Jelaskan apakah diimplementasikan sendiri atau diambil dari sumber lain.

Baseline 1: Pipeline Sekuensial (Single-node Pandas)

Pipeline sederhana berbasis Pandas dan Scikit-learn tanpa distribusi komputasi, dijalankan pada satu mesin lokal. Dataset diproses secara sekuensial baris per baris tanpa partisi. Model Random Forest dari sklearn.ensemble dilatih menggunakan fitur fisikokimia saja (tanpa pop_density). Baseline ini diimplementasikan sendiri sebagai *benchmark* awal untuk mengukur *throughput* dan akurasi sebelum integrasi Spark dan fitur urbanisasi.

Baseline 2: Model Fisikokimia-Only (tanpa pop_density)

Model RF dan XGBoost dilatih menggunakan pipeline Medallion Architecture yang sama, namun tanpa menyertakan fitur pop_density. Baseline ini bertujuan mengukur seberapa besar kontribusi variabel tekanan urbanisasi terhadap peningkatan akurasi prediksi WQI menjawab langsung pertanyaan ilmiah utama proposal ini. Baseline ini diimplementasikan sendiri sebagai *ablation study*.

Tabel 2. Baseline

Baseline	Metode	Fitur	Implementasi
B1	Pandas + Sklearn (sekuensial)	8 fisikokimia	Sendiri
B2	Spark RF/XGBoost (tanpa pop_density)	8 fisikokimia	Sendiri (ablation study)
Proposed	Spark RF/XGBoost (lengkap)	8 fisikokimia + pop_density	Sendiri

6. EVALUASI

Tentukan minimal satu metrik kuantitatif yang jelas. Contoh metrik yang umum digunakan: throughput (baris/detik), latensi end-to-end pipeline, akurasi prediksi (RMSE/MAE untuk regresi, silhouette score untuk clustering), atau rasio kompresi penyimpanan. Sebutkan nilai acuan (baseline score) yang ada di literatur atau yang Anda targetkan.

Tabel 3. Matrik evaluasi yang direncanakan

Matrik	Acuan Baseline	Target
Throughput ingesti (baris/dtk)	~5.000 (Pandas sekuensial)	≥ 50.000 (Spark distributed)
Latensi pipeline end-to-end	~60 menit (sekuensial)	≤ 20 menit (Spark)
Akurasi klasifikasi WQI	~75% (B2, tanpa pop_density)	≥ 85%
RMSE prediksi skor WQI	~0.55 (B2, tanpa pop_density)	≤ 0.35
F1-Score (macro avg)	~0.70 (B2)	≥ 0.83
Feature importance pop_density	—	Masuk top-3 fitur

Nilai acuan baseline B2 mengacu pada hasil eksperimen awal dengan dataset subset (10% dari total), serta merujuk pada hasil yang dilaporkan dalam paper *"A combined water quality pollution prediction model based on the Spark big data platform"* (ResearchGate, 2022) yang melaporkan akurasi model berbasis parameter fisikokimia saja berkisar 74–79%.

7. TANTANGAN ETIS DAN RISIKO SOSIAL

Tulis satu paragraf yang membahas: (A) minimal dua tantangan etis atau risiko sosial yang spesifik untuk proyek Anda - misalnya privasi data, potensi bias dalam model prediksi yang memengaruhi kebijakan, transparansi algoritma terhadap pemangku kepentingan, atau ketergantungan pada data yang tidak representatif - dan (B) strategi mitigasi yang spesifik dan praktis. Bagian ini dinilai berdasarkan kedalaman pemikiran.

Proyek ini menghadapi setidaknya dua tantangan etis yang perlu diantisipasi secara serius.

Pertama, potensi bias representasi antar tipe badan air dan wilayah. Dataset England mencakup berbagai tipe badan air — River, Lake, Estuarine, Effluent, hingga Sewage — dengan distribusi yang tidak merata. Rekaman dari tipe *Effluent* dan *Sewage* (limbah buangan) secara inheren memiliki karakteristik kimia yang sangat berbeda dari badan air alami, sehingga jika diikutsertakan tanpa pemisahan, model ML dapat mempelajari pola yang tidak representatif untuk kualitas air lingkungan. Selain itu, area monitoring yang lebih padat di wilayah urban England (seperti Greater London dan West Midlands) dibandingkan wilayah rural berpotensi membuat model lebih akurat untuk kawasan padat penduduk dan kurang andal untuk daerah pedesaan yang justru bergantung pada sumber air alami.

Jika model ini diadopsi sebagai dasar kebijakan alokasi sumber daya air oleh otoritas lingkungan seperti *Environment Agency* UK, maka wilayah rural dapat terabaikan (*algorithmic neglect*). Strategi mitigasi: melakukan stratified sampling berdasarkan tipe badan air dan wilayah administratif (county) saat pembagian train/test set, serta melaporkan metrik akurasi secara terpisah per tipe badan air agar keterbatasan model terdokumentasi secara transparan. Khusus untuk pemodelan kualitas air alami, dataset disarankan difilter hanya pada tipe *River*, *Lake*, dan *Estuarine*.

Kedua, transparansi model dan risiko generalisasi lintas negara. Model yang dilatih pada data England berpotensi digunakan sebagai justifikasi untuk diadaptasi ke konteks Indonesia (sesuai tujuan jangka panjang proposal). Namun, kondisi fisikokimia, standar regulasi kualitas air, serta pola urbanisasi di Indonesia berbeda secara signifikan dari England. Penggunaan model ini secara langsung tanpa validasi lokal dapat menghasilkan prediksi yang menyesatkan bagi pemangku kepentingan seperti BPPIKHL atau KLHK.

Di sisi lain, model XGBoost dan Random Forest bersifat *black box* bagi non-teknisi, sehingga tanpa penjelasan yang memadai dapat menimbulkan ketidakpercayaan publik. Strategi mitigasi: mengintegrasikan SHAP (SHapley Additive Explanations) untuk menghasilkan visualisasi kontribusi tiap fitur per prediksi, mendokumentasikan secara eksplisit bahwa model ini dilatih pada konteks England dan memerlukan fine-tuning sebelum diterapkan di negara lain, serta menyertakan *disclaimer* yang jelas pada dashboard Apache Superset bahwa output model bersifat indikatif dan bukan keputusan kebijakan final.

REFERENSI

Gunakan format referensi IEEE. Sitasi disusun dan ditulis berdasarkan sistem nomor sesuai dengan urutan pengutipan. Hanya pustaka yang disitasi pada usulan penelitian yang dicantumkan dalam Referensi.

[1] Y. Zhang et al., "A Comprehensive Surface Water Quality Monitoring Dataset 1940–2023: 2.82 Million Record Resource for Empirical and ML-Based Research," Scientific Data, Nature, vol. 12, 2025. [Online]. Available: https://www.nature.com/articles/s41597-025-04715-4

[2] H. Liu, X. Chen, and J. Wang, "A combined water quality pollution prediction model based on the Spark big data platform," Environmental Science and Pollution Research, 2022. [Online]. Available: https://www.researchgate.net/publication/362162451

[3] W. Shi et al., "Evaluation and prediction of water quality in the dammed estuaries and rivers of Taihu Lake," Environmental Science and Pollution Research, 2021. [Online]. Available: https://www.researchgate.net/publication/348294938

[4] C. Ren et al., "An analysis of the relationship between spatial patterns of water quality and urban development in Shanghai, China," Environmental Monitoring and Assessment. [Online]. Available: https://www.researchgate.net/publication/222702874

[5] P. Shi et al., "Urbanization and its effects on water quality in China," Science of the Total Environment, vol. 601–602, pp. 1554–1564, 2017. [Online]. Available: https://doi.org/10.1016/j.scitotenv.2017.05.222

[6] X. Li et al., "Remote Sensing-Based Assessment of Water Quality in River Systems," Remote Sensing, MDPI, vol. 18, no. 5, p. 840, 2026. [Online]. Available: https://www.mdpi.com/2072-4292/18/5/840

[7] ScienceDirect, "Urban pressures and surface water quality: A review of recent advances," Journal of Hazardous Materials, 2025. [Online]. Available: https://doi.org/10.1016/j.jhazmat.2025.023517

[8] WorldPop, "United Kingdom Population Density (1km)," WorldPop Hub, University of Southampton. [Online]. Available: https://hub.worldpop.org

[9] WorldPop, "United Kingdom Population Counts (100m)," WorldPop Hub, University of Southampton. [Online]. Available: https://hub.worldpop.org

[10] Environment Agency, "Water quality data archive," UK Government Open Data, 2024. [Online]. Available: https://environment.data.gov.uk/water-quality