BAB I

PENDAHULUAN

1.1 Latar Belakang

Kualitas air permukaan berkaitan dengan kesehatan masyarakat, keberlanjutan ekosistem, dan ketersediaan sumber air baku. Kepentingan tersebut tercermin dalam Sustainable Development Goals (SDG) 6 yang menempatkan air bersih dan sanitasi sebagai sasaran pembangunan global. Pengelolaan kualitas air memerlukan data pemantauan yang konsisten agar perubahan kondisi badan air dapat dikenali dan keputusan penanganan pencemaran tidak hanya bertumpu pada pengamatan sesaat. Ketersediaan data yang dapat diolah dan dibandingkan karena itu menjadi bagian penting dari pemantauan kualitas air berbasis bukti [1].

Perubahan lingkungan akibat urbanisasi merupakan salah satu tekanan yang perlu diperhitungkan dalam pemantauan tersebut. Pertambahan kawasan terbangun, perubahan tata guna lahan, serta peningkatan limbah domestik dan industri dapat mengubah karakteristik fisikokimia badan air. Luo dkk. [2] menemukan bahwa perkembangan kawasan perkotaan di Liangjiang New Area berkaitan dengan penurunan kualitas air sungai dan perubahan komunitas makroinvertebrata. Hasil itu menunjukkan bahwa kondisi kualitas air tidak hanya perlu dibaca dari parameter fisikokimia, tetapi juga dari konteks spasial di sekitar lokasi pemantauan. Dalam penelitian ini, kepadatan penduduk digunakan sebagai proksi tekanan urbanisasi, bukan sebagai ukuran langsung sumber pencemar.

Peluang untuk menguji hubungan tersebut semakin terbuka setelah Karim dkk. [1] menyediakan 2,82 juta rekaman kualitas air permukaan dari lima negara untuk periode 1940–2023. Rekaman dari England dipilih sebagai studi kasus karena tersedia bersama informasi lokasi yang dibutuhkan untuk menghubungkannya dengan data kepadatan penduduk WorldPop [3]. Volume, rentang waktu, dan keragaman kondisi data menuntut proses penyaringan, pembersihan, serta pembentukan fitur yang dapat ditelusuri. Apache Spark menyediakan mekanisme pemrosesan terdistribusi untuk pekerjaan semacam ini [4], tetapi keunggulannya terhadap pemrosesan sekuensial tetap perlu dibuktikan pada data dan perangkat komputasi yang digunakan dalam penelitian.

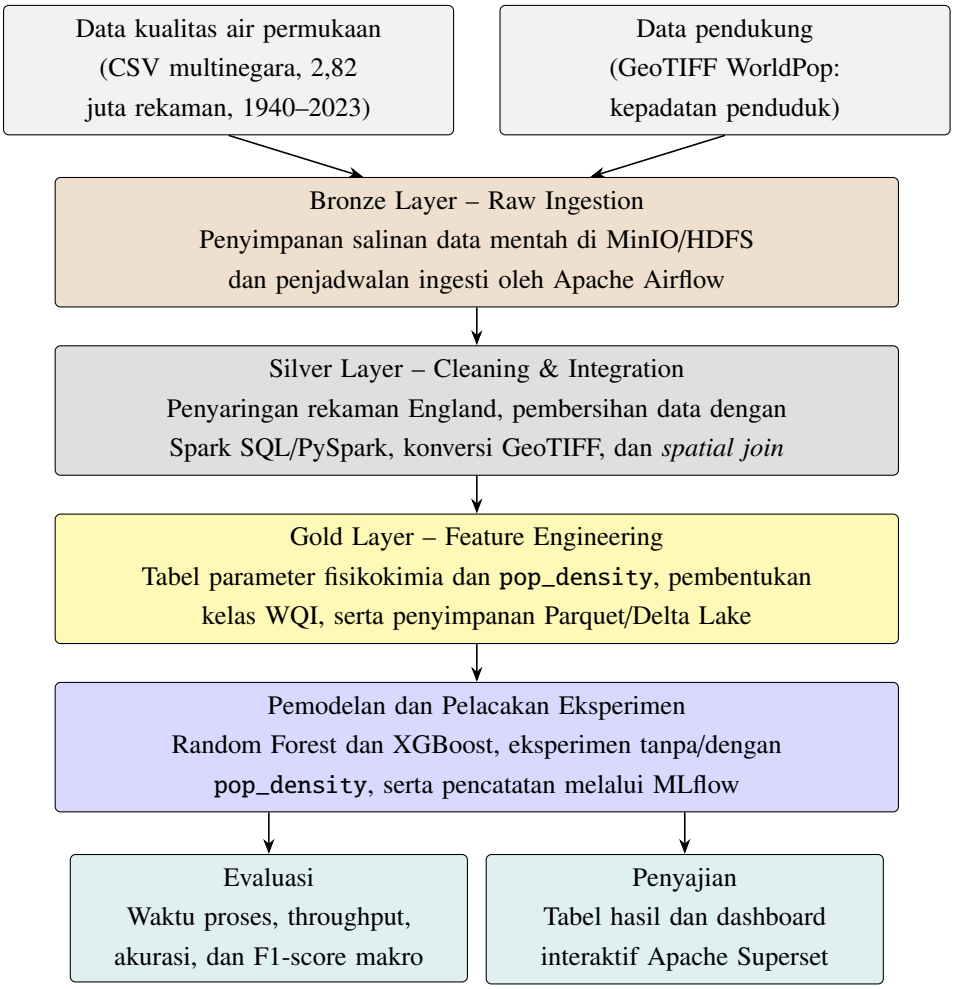
Penelitian Sun dan Fan [5] memperlihatkan bahwa Spark dapat digunakan dalam pemodelan pencemaran air berbasis parameter fisikokimia. Akan tetapi, sumber

yang ditelaah belum menjawab dua persoalan pada rancangan penelitian ini: apakah kepadatan penduduk memberi informasi tambahan ketika digabungkan dengan parameter fisikokimia dan apakah pilihan algoritma menghasilkan perbedaan kinerja klasifikasi Water Quality Index (WQI). Kedua persoalan tersebut tidak dapat dijawab hanya dari satu hasil pelatihan model. Diperlukan perbandingan terkontrol antara model dengan dan tanpa fitur kepadatan penduduk, kemudian perbandingan Random Forest dan XGBoost pada pembagian data serta prosedur evaluasi yang sama.

Berdasarkan kebutuhan tersebut, penelitian ini menyusun alur data berlapis menggunakan Medallion Architecture. Lapisan *Bronze* menyimpan data mentah, lapisan *Silver* menangani pembersihan dan penggabungan spasial, sedangkan lapisan *Gold* menghasilkan tabel fitur dan kelas WQI yang mengacu pada metode CCME [6]. Penelitian diarahkan pada tiga pengujian, yaitu evaluasi kinerja pipeline Apache Spark terhadap Pandas, analisis pengaruh penambahan kepadatan penduduk, serta perbandingan Random Forest dan XGBoost. Susunan ini memungkinkan aspek rekayasa data dan pemodelan dinilai secara terpisah tanpa menganggap bahwa pemrosesan terdistribusi atau penambahan fitur pasti memberikan hasil yang lebih baik.

1.2 Alur Penelitian

Alur penelitian disusun dari proses ingesti data hingga penyajian hasil sebagaimana ditampilkan pada Gambar 1.1. Setiap lapisan menghasilkan keluaran yang menjadi masukan bagi tahap berikutnya sehingga perubahan data dapat ditelusuri.



Gambar 1.1 Alur pengolahan data, pemodelan, dan evaluasi penelitian

1.3 Rumusan Masalah

Rumusan masalah penelitian ini adalah sebagai berikut:

1. Bagaimana perbedaan kinerja pipeline Medallion Architecture berbasis Apache Spark dan pipeline sekuensial berbasis Pandas jika dievaluasi berdasarkan waktu pemrosesan dan throughput?
2. Seberapa besar pengaruh penambahan fitur kepadatan penduduk terhadap kinerja klasifikasi WQI jika dianalisis melalui perbandingan dengan penggunaan parameter fisikokimia saja?
3. Bagaimana perbedaan kinerja Random Forest dan XGBoost jika dibandingkan dalam klasifikasi WQI pada data dan prosedur evaluasi yang sama?

1.4 Tujuan Penelitian

Tujuan penelitian disusun sejajar dengan rumusan masalah sebagai berikut:

1. Mengevaluasi perbedaan kinerja pipeline Medallion Architecture berbasis Apache Spark dan pipeline sekuensial berbasis Pandas berdasarkan waktu pemrosesan dan throughput.
2. Menganalisis pengaruh penambahan fitur kepadatan penduduk terhadap kinerja klasifikasi WQI melalui perbandingan dengan model yang hanya menggunakan parameter fisikokimia.
3. Membandingkan kinerja Random Forest dan XGBoost dalam mengklasifikasikan WQI pada data dan prosedur evaluasi yang sama.

1.5 Batasan Masalah

Agar pengujian tetap terarah, penelitian ini menggunakan batasan berikut:

1. Data utama berasal dari dataset kualitas air permukaan periode 1940–2023 yang dipublikasikan oleh Karim dkk. Rekaman yang dianalisis dibatasi pada wilayah England, sedangkan data kepadatan penduduk berasal dari WorldPop.
2. Variabel prediktor dibatasi pada delapan parameter fisikokimia yang tersedia dalam dataset dan fitur kepadatan penduduk. Kepadatan penduduk diperlakukan sebagai proksi tekanan urbanisasi sehingga hasil penelitian tidak ditafsirkan sebagai hubungan sebab-akibat.
3. Kelas WQI dibentuk dengan mengacu pada metode CCME dan ketersediaan parameter pada dataset. Analisis dibatasi pada klasifikasi kelas WQI; akurasi dan F1-score makro digunakan sebagai metrik utama, sedangkan RMSE tidak digunakan untuk menilai label kelas. Apabila label dihitung dari parameter pada pengamatan yang sama, keluaran model ditafsirkan sebagai otomasi klasifikasi, bukan prediksi kondisi pada waktu berikutnya.
4. Perbandingan algoritma dibatasi pada Random Forest dan XGBoost. Pengaruh kepadatan penduduk diuji melalui perbandingan model dengan dan tanpa fitur tersebut pada pembagian data serta prosedur evaluasi yang sama.
5. Perbandingan pipeline dibatasi pada pemrosesan *batch* menggunakan Pandas pada satu proses dan Apache Spark pada lingkungan lokal yang sama. Kinerja diukur dari waktu pemrosesan ujung ke ujung dan throughput; pengujian tidak mencakup *streaming*, layanan produksi, biaya komputasi awan, atau ketahanan sistem terhadap kegagalan simpul.
6. Infrastruktur penelitian dibatasi pada komponen yang dijalankan melalui Docker Compose, yaitu Apache Spark, MinIO/HDFS, Apache Airflow, MLflow, dan Apache Superset. Penelitian tidak melakukan validasi model menggunakan data kualitas air Indonesia.

1.6 Manfaat Penelitian

Manfaat yang diharapkan dari penelitian ini meliputi:

1. Manfaat teoretis berupa bukti empiris mengenai informasi tambahan yang diberikan oleh kepadatan penduduk dalam klasifikasi WQI setelah parameter fisikokimia diperhitungkan. Hasil perbandingan algoritma juga memberikan gambaran tentang kesesuaian Random Forest dan XGBoost pada data yang digunakan.
2. Manfaat praktis berupa rancangan pipeline berlapis yang dapat direproduksi untuk membersihkan, menggabungkan, dan menyiapkan data kualitas air berskala besar. Hasil pengukuran pipeline dan dokumentasi eksperimen dapat menjadi dasar pemilihan metode pemrosesan serta pengembangan sistem pemantauan berikutnya.

DAFTAR PUSTAKA

[1] M. R. Karim dkk., "A comprehensive dataset of surface water quality spanning 1940-2023 for empirical and ML adopted research", *Scientific Data*, vol. 12, 2025. sumber: https://doi.org/10.1038/s41597-025-04715-4

[2] K. Luo dkk., "Impacts of rapid urbanization on the water quality and macroinvertebrate communities of streams: A case study in Liangjiang New Area, China", *Science of The Total Environment*, vol. 621, hlmn. 1601–1614, 2018. sumber: https://doi.org/10.1016/j.scitotenv.2017.10.068

[3] WorldPop, *United kingdom population density (1km)*, WorldPop Hub, University of Southampton, 2024. sumber: https://hub.worldpop.org

[4] M. Zaharia dkk., "Apache spark: A unified engine for big data processing", *Communications of the ACM*, vol. 59, no. 11, hlmn. 56–65, 2016. sumber: https://doi.org/10.1145/2934664

[5] Z. Sun dan Y. Fan, "A combined water quality pollution prediction model based on the Spark big data platform", *Journal of Water Supply: Research and Technology-Aqua*, vol. 71, no. 9, hlmn. 963–974, 2022. sumber: https://doi.org/10.2166/aqua.2022.036

[6] "Canadian water quality index 1.0, technical report, user's manual", Canadian Council of Ministers of the Environment, Technical Report, 2007.